DASE7506 MP1 小语言模型挑战赛 · 报告

学号　3036837693（王昱程）｜2026-09-22｜评测协议　`7506-mp1-wt2-v2`｜代码仓库　https://github.com/ethanwang2747/DASE7506hw1

本报告另有英文版：report-en.md。

除特别标注外，BPB　都是　**CPU　fp32、validation　split、选中权重**　的实测值。可复核的随包材料：`checkpoint.pt`、`config.json`、`score_test.json`、`RUN_LOG.csv`、`report/evidence.csv`（逐 run 一行，由各 run 的 `metrics.json` 生成）与 `report/figs/`。

1. 摘要与最终成绩

方法以 **pre-norm 架构栈（RMSNorm / SwiGLU / QK-Norm / 零初始化 / 绑定头）＋ Muon ＋ 8.9M 容量的长计划（28,800 步 ≈ 65 epoch）＋ EMA ＋ 三代 born-again 双教师蒸馏（T=4、α=0.7）** 为主线，配以「每次只动一个旋钮、双 seed 配对」的超参探底。test 2.1013 → **1.4269**（−0.674 BPB）：蒸馏的配对消融值 −0.0453，架构栈 + Muon 打包值 −0.18~−0.23。三条资源限制全部实测通过；每张表背后的逐 run 数据随包发布为 `report/evidence.csv`。

成绩项	数值	出处
初始基线 E0：validation / **test** BPB	2.0711 / **2.1013**	`report/evidence.csv`
等 7,200 步基线配方（双 seed 均值）	1.7049	`report/evidence.csv`
最终冻结 validation BPB	**1.407431**	`report/evidence.csv`
最终冻结 test BPB	**1.426939**	`score_test.json`
test 耗时	**28.72 s** vs 6.11 s = **4.70×**（旧锚 6.55 s → 4.39×）	`RUN_LOG.csv`
峰值内存	**2.12 GiB**（2,220,248 kB，/usr/bin/time -v）	`RUN_LOG.csv`
未压缩资产	35,652,341 B ≈ **34.0 MiB**（8,907,696 参数）	`checkpoint.pt`

val 1.4074 是约 100 个 run 上的选择最小值，其配方族（同配方双 seed）均值为 1.4080；val→test 的实际漂移 +0.0195（E0 锚点 +0.0302，见第 6.1 节与第 8 节）。

2. 协议与约束

2.1 评分口径

BPB 定义为

```
BPB = Σ_w Σ_t ( −log2 P(正确 token) ) ÷ 该 split 的全部原始 UTF-8 字节数
```

有两点容易读错：(1) **分母是字节，不是 token**，分词器固定不可换；(2) 文本先 BPE 编码，再按 **256 token 的不重叠窗口**切分（含末尾短窗），窗口之间不携带状态，只共享一个边界 token；**每个目标只计分一次**，首个 token 不计分但其字节计入分母。评测器还要求 `[batch, time, 2048]` 形状且全部有限（mask 不能有 `-inf`）、`|logsumexp(logp, -1)| ≤ 1e-3`。

split	计分目标数	UTF-8 字节数	token 数
train	——	10,951,562	3,613,343
validation	376,599	1,148,007	376,600
test	428,405	1,292,013	428,406

test/val 的字节比 1.1254、目标数比 1.1376，用来把 validation 计时外推到 test。开发与选型只看 validation：test 至今只被**基线族**跑过 3 次（E0 正式两次 + 一次 10 步冒烟），**候选学生模型 0 次**。

2.2 三条资源限制与预算换算

三条限制针对**同一个冻结后的预测器**测量；`evaluate.py` 的 `device_metrics()` 在 CPU 上恒返回 0，必须自己量。

限制	预算	冻结模型实测
CPU 时间 ⩽ 5×	test 6.5496 s ⇒ **32.75 s**	**28.72 s** vs 6.11 s = **4.70×**
峰值内存	⩽ 4 GiB	**2.12 GiB**（2,220,248 kB，/usr/bin/time -v）
未压缩资产	⩽ 64 MiB（⩽ 16,777,216）	35,652,341 B ≈ **34.0 MiB**（8,907,696）

时间预算是所有尺寸决策的锚点：事前的「5× ≈ 4× FLOPs ≈ 4.1–4.5M 参数」换算偏保守——8.9M 的冻结模型实测只花 4.70×。换算只能当起点，预算须以本机实测的基线 `seconds` 为准（服务器 CPU 更慢，同模型可到 29–40 s）。

2.3 被约束排除的路线

路线	排除依据
kNN-LM / 检索增强	datastore ≈ 922 MB ≫ 64 MiB；CPU 检索必爆 5× 时间
dynamic evaluation / 测试时训练	评测时反向传播必超 5× CPU 时间
int8 量化放大单模型	评测固定 CPU FP32，反量化推理超时
跨 seed 直接权重平均	损失盆地不同；轨迹内 EMA 与 logit 集成仍可用
纯 Mamba / 线性注意力	`selective_scan` 仅 CUDA，短序列 CPU 上更慢
n-gram 输出端插值	另机实测无效；第 3.1 节给出其量级上限

2.4 合规性证据（每条实验后复核）

- 默认路径逐位不变：`--implementation model --steps 10` 冒烟的 checkpoint sha256 `2ce13a32…`、validation BPB `3.579821969345922`、step-10 loss 与记录逐位一致（须在空闲机器上做， 否则只对到 6e-11 相对差异）。
- 契约测试 5/5 OK；禁改文件（`model.py` / `common.py` / `evaluate.py` / `tests/` / `configs/baseline.json` / `data/*`）与原始 分发包逐成员 sha256 一致。

3. 诊断：限制在哪

协议的两条硬约束是「独立 256 窗」与「固定 3.61M token 的课程文本」。

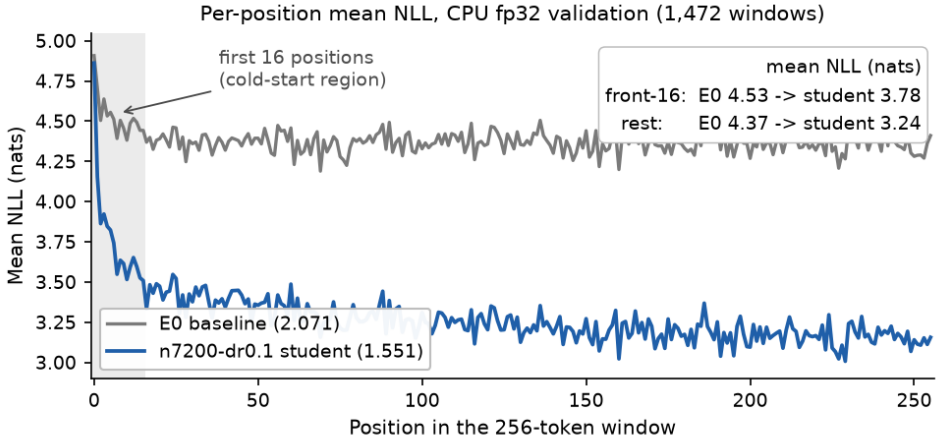
3.1 逐位置损失：窗口冷启动真实但很小

复刻 scorer 的同一套非重叠 256-token 窗口，统计每个位置的平均 NLL （校验：Σ(每位置 NLL × 计数) 精确复现 scorer 的 BPB，E0 为 2.0710809705 vs 2.0710809771）：

指标	基线（val 2.0711）	训练后的学生（val 1.5511）
position 0 平均 NLL	4.9074 nats	4.8614 nats
前 16 个位置	4.5294	3.7751
后 16 个位置	4.3530	3.1508
前 16 / 后 16	1.0405	**1.1981**
窗口其余位置	4.3659	3.2442
前 16 占总 NLL 的份额（token 份额 6.25%）	6.47%	7.20%
冷启动超额占总 NLL	0.25%	**1.19%**

训练后的学生在前 16 个位置上比尾部贵约 20%，承载约 1.2% 的验证集总 NLL；把它们变得和尾部一样便宜值 **≈0.018 BPB**（1.5511 → ≈1.533） ——是「容量 +1.31M 参数」全部收益（0.0506）的约 1/3、seed 极差（0.0068）的 2.7 倍，但**比撑起一个策略所需的小一个数量级。模型越 强，残差损失越向前几个 token 集中**（0.25% → 1.19%）。见图 1。

图 1. 逐位置平均 NLL：基线 E0 与训练后学生在 256-token 窗口内各位置的平均损失（CPU fp32 validation）



3.2 数据量 vs 参数量：真正的限制是「数据受限 + 多 epoch」

课程训练文本只有 **3,613,343 个 token**：1,200 步 = 9,830,400 个目标 ≈ 2.7 epoch；7,200 步 ≈ **16.3 epoch**；14,400 步 ≈ **32.6 epoch**。 基线配方（1.09M 参数）的 token/参数比是 3.3，而 6.64M 参数的候选学生 只有 **0.54 token/参数**。「加参数」最初被排除（快筛里 8.1M 没赢过 6.6M），但该结论被推翻：容量要**配上长计划与正则**才变现——7,200 步配 dropout 0.1 后 8.9M 反超 6.6M（配对 −0.009），14,400 步时收益约翻倍； 主轴是**训练方法 × 容量**。教师侧已过拟合（15.0M / 4,800 步的教师 1.5246 优于 20.1M 教师，第 6.3 节）；学生侧尚未到拐点（四个 7,200 步 学生臂的尾部**没有一个反弹**，dropout 0 臂的末端上翘被 dropout 0.1 消除，第 5.4 节）。

4. 方法

4.1 架构栈（`code/student.py`，自包含单文件）

相对课堂基线（`model.py`：LayerNorm + 4×GELU + 可学习绝对位置 + 绑定 头）的改动：

改动	内容	理由
RMSNorm 取代 LayerNorm	先转 float 计算再回写原 dtype	fp16/bf16 数值稳定
SwiGLU 取代 GELU-4×	hidden = 8/3 × width，取 8 的倍数	预算与 3 · width · hidden 持平
QK-Norm	每个注意力头维度上做 RMSNorm	稳定长计划训练
零初始化	`attn.proj.weight` 与 `mlp.down.weight` 置零	每个 block 是恒等映射
绑定头 / 无偏置	`tie=True`、`bias=False`	与基线一致；解绑无收益（第 5.4 节）
位置编码	保留可学习绝对位置	context 固定为 256，RoPE 收益很小

架构代码必须全写在一个文件里（`common.make_model()` 只对**单文件**实现 模块做 sha256）；checkpoint 必须能只靠 `config` 重建（断言 `context == 256`、`vocab == 2048`）。

项	冻结配方的取值
模型	vocab 2048 / w336 / h6 / d6 / ctx 256；RMSNorm、SwiGLU、QK-Norm
dropout	0.05
优化器	Muon（lr 0.03、momentum 0.95、解耦 wd 0.05）+ AdamW（lr 1e-3）、裁剪 1.0
计划	100 步 warmup + cosine 衰减到峰值 10%，共 28,800 步；32×256 = 8,192/步
EMA / 蒸馏 / seed	0.9995（EMA 1.407431 / raw 1.433284）；T=4.0、α=0.7；seed 42

4.2 Muon 优化器

Newton–Schulz 5 步正交化（系数 3.4445, −4.7750, 2.0315，bfloat16 内 完成）。参数分组：只有非输出头的 2D `nn.Linear` 矩阵交给 Muon，嵌入、 norm gain、bias、输出头留在 AdamW；更新量乘 `max(1, rows/cols)**0.5` 缩放。默认路径逐位不变（第 2.4 节）。

4.3 长计划 + dropout

每步随机抽 32 个起点、各取 257 个连续 token（32×256 = 8,192 个目标）； 基线配方为 AdamW lr 1e-3 / weight_decay 0.1 / 梯度裁剪 1.0、100 步 warmup 后 cosine 衰减到峰值的 10%。dropout 施加在嵌入后与两个残差分支 各一次；`nn.Dropout` 在 eval 时是恒等映射，**打分不受 dropout 影响**。 `--steps` 同时决定 cosine 周期，因此「多训步数」与「换调度形状」纠缠在 一起——4,800 步的 run 不是 7,200 步 run 的前缀（第 4,800 步时前者 1.6289，后者已收敛到 1.5596）。

4.4 EMA（指数滑动平均）

影子权重在每步 `optimizer.step()` 后更新：`avg = decay·avg + (1−decay)·param`；训练结束时 raw 与 averaged 各用 CPU fp32 打一次 validation、取优者写进 checkpoint。规则是 **horizon 必须匹配计划 长度**：让 `1/(1−decay)` ≲ 步数预算的 15%。7,200 步用 0.999（horizon 1,000 步 = 13.9%，初始化残留可忽略）； 14,400 步用 0.9995；1,200 步只能 用 0.99——违反时 0.999 配 1,200 步会让 30% 的随机初始化留在平均值里， EMA 反而差 0.366 BPB。

4.5 多教师集成蒸馏（核心机制）

损失为逐 token 的 `α·T²·KL(log_softmax(student/T) ‖ teacher_softmax) + (1−α)·CE`；多教师 时各自 softmax 后对 log-prob 取算术平均再归一化（等价于概率的**几何 平均**再归一化）。教师用 `common.make_model(...)` 重建、设 `eval()` 与 `requires_grad_(False)`；每个教师的 path / sha256 / config / seed 都写进 `metrics.json` 的谱系字段。成本全在训练侧（每步多两次教师前向，步时约 **2.4×**）；**评测零成本**。

5. 证据

本节覆盖三条要求证据：初始基线、等「已处理训练目标数」的对比、核心机制 的消融（BPB 均为 CPU fp32 / validation split）。蒸馏消融两臂同配置， **只差 `--distill-checkpoint/-T/-alpha`**；表中「Δ」为**负值 = 改善**。

5.1 初始基线 E0

配方	参数	训练目标数	train s	val BPB	test BPB	评分 s
课堂基线	1,088,256	9,830,400	23.07	2.0711	**2.1013**	6.7486 / 6.5496

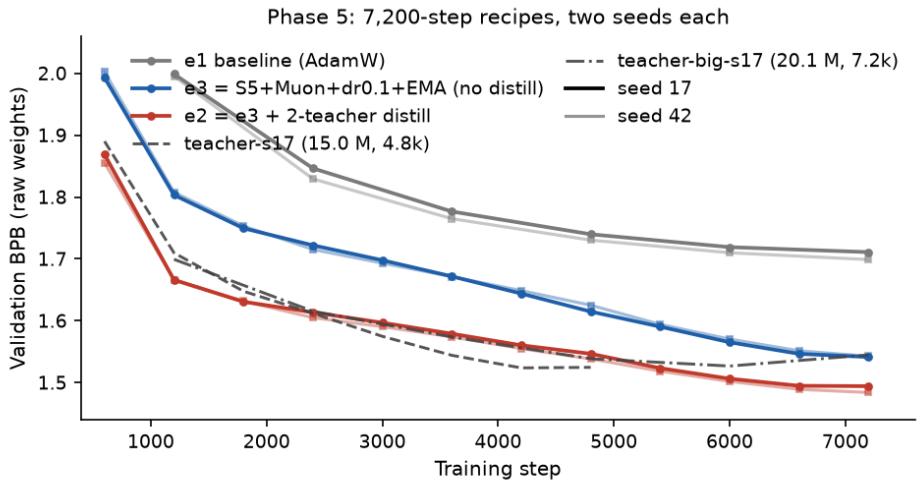
E0 是全项目**唯一跑过 test 的 run**，也是 5× 预算（32.7 s）与 val→test 换算的唯一实测锚点（比值 1.01459；加性换算 +0.0302）。两次 test 只有 `seconds` 不同：分数可复现，计时受负载影响。

5.2 等「已处理训练目标数」的对比（要求 2）

尺度	配方	参数	已处理目标数	seed 17	seed 42	均值
7,200 步	**基线配方**	1,088,256	58,982,400	1.7109	1.6989	**1.7049**
	6.6M + Muon + dr0.1 + EMA	6,640,128	58,982,400	1.5169	1.5191	**1.5180**
	+ 双教师蒸馏 T=4/α=0.7	6,640,128	58,982,400	1.4752	1.4702	**1.4727**
14,400 步	基线配方	1,088,256	117,964,800	1.6796	—（单 seed）	1.6796
	6.6M 学生（无蒸馏）	6,640,128	117,964,800	1.4977	1.4953	**1.4965**
	+ 三教师蒸馏	6,640,128	117,964,800	1.4777	1.4775	**1.4776**

等目标数下本方法比基线配方低 **0.232 BPB**，同尺度 14,400 步对比给出 **−0.183**。这一组打包了多个变量，**不能用于归因**（见 5.3 与第 6.4 节）。基线配方无 EMA 开关。见图 2。

图 2. 7,200 步各配方的 validation BPB 曲线：基线配方、无蒸馏学生与双教师蒸馏学生，各两个 seed（raw 权重，CPU fp32 validation）



Intermediate points are the periodic on-device validation on raw weights; the EMA-selected final values are lower (e2 1.475/1.470, e3 1.517/1.519). Teachers are shown as reference curves.

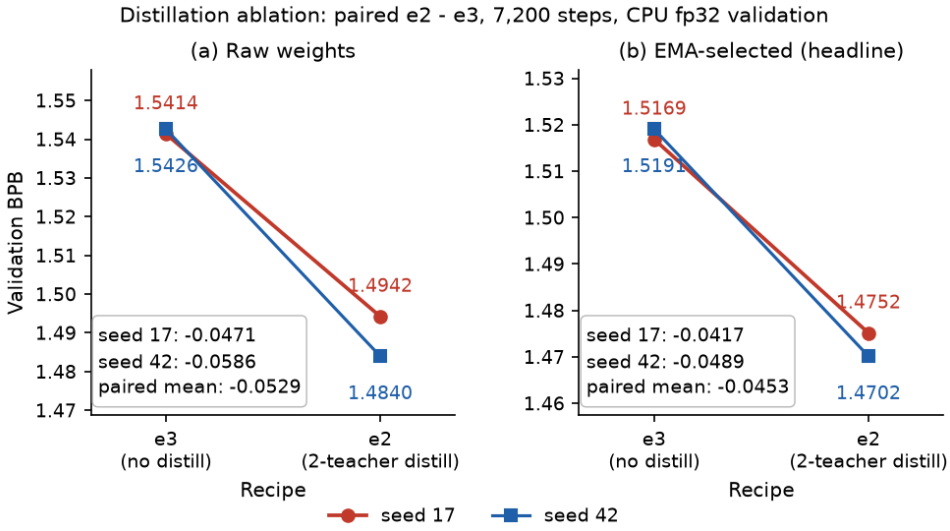
5.3 核心机制消融：蒸馏（要求 3）

尺度	seed	蒸馏臂（选中）	对照臂（选中）	Δ（选中）	Δ（raw）
7,200 步	17	1.4752	1.5169	**−0.0417**	−0.0471
7,200 步	42	1.4702	1.5191	**−0.0489**	−0.0586
7,200 步	**均值**	—	—	**−0.0453 ± 0.004**	−0.0529
14,400 步	17	1.4777（三 EMA 教师）	1.4977	**−0.0200**	—
14,400 步	42	1.4775（三 EMA 教师）	1.4953	**−0.0178**	—
14,400 步	**均值**	1.4776	1.4965	**−0.0189**（增益随计划衰减，教师组已换）	—

7,200 步下蒸馏的配对增益 −0.0453，两个 seed 同号同量级，约为 7,200 步 重复 run 散度（sd ≈0.003–0.007）的 7–20 倍、1,200 步噪声地板（sd 0.0088）的 5 倍——**唯一干净越过噪声地板的杠杆**。1,200 步 T/α 网格 （同配方、同 seed，只改蒸馏参数）：无蒸馏参照 1.6709；T=2.0/α=0.7 单 教师 1.5954；**T=4.0/α=0.7 单教师 1.5756**；T=2.0/α=0.9 1.6047； T=2.0/α=0.7 双孪生教师 1.5940——每臂优于参照 0.066–0.095 BPB。网格 内部

T=4 优于 T=2 约 0.0198，α=0.9 比 0.7 差 0.0093（≈0.9 sd，未 分辨），第二个教师只值 +0.0014（0.13 sd）——它与第一个近乎孪生（只差 0.0010），故**不能**说明「多样教师」无用（集成效应见第 6.2 节）。见图 3。

图 3. 7,200 步蒸馏的配对效应：蒸馏臂与无蒸馏对照臂，两个 seed 的 raw 与 EMA 选中值（CPU fp32 validation）



5.4 其它已裁决的机制（均为配对实验）

机制	配对照据	结论	成本
dr0.1 vs 0	1.5512 vs 1.5633（2 run）	保留 0.1，**−0.0121**，2/2 一致	零成本
EMA 0.999	−0.0245/−0.0235/−0.0190/−0.0138	**4/4 全选**，均值 −0.0202	多一次
步数 7,200 → 14,400	1.5180 vs 1.4965	**仅 −0.0215**，raw 曲线走平	2× 训练步数
Muon vs AdamW（1,200）	1.7835/1.7620/1.7540 vs 1.8980/1.8946/1.8472	**−0.1145 / −0.1326 / −0.0932**；lr 0.05 最佳（1.7215），优于 0.01/0.02（1.7583/1.7620）	+8–14%
失败探针：解绑 / w320 / lr 0.08	1.6458 vs 1.6473；1.6443 vs 1.6473；1.6448 vs 1.6473	−0.0015 / −0.0030 / −0.0025，**都不通过**	解绑 +589,824（8.9%）；w320 +1.49M
跨 seed 平均	0.5×（两 seed 的 EMA）	**3.2098 灾难**（成员 1.4552 / 1.4719）	2×
轨迹内 SWA（k≤4）	wd 0.05 末段快照	1.4594–1.4616，**不如同 run 的 EMA**（1.4578）；再平均 EMA 快照更差（1.4699）	k×

5.5 最终配方的组装路径

最终配方沿「每次只动一个旋钮、双 seed 配对」贪婪组装（CPU fp32 validation，raw/EMA 取优）：

配方变动	配对差（seed 17 / 42）	结论
weight decay 0.1 → 0.05（8.9M @14,400 步）	−0.0278 / −0.0197	**最大单旋钮增益**
born-again 教师 + 28,800 步	−0.0072 / −0.0068	超可加（预期 −0.0093 / 实测 −0.0121）
教师换成上一代（第三代）蒸馏	−0.0032 / −0.0008	方向仍正但已进噪声区
dropout 0.1 → 0.05（28,800 步）	−0.0035 / −0.0028	放松轴同样成立（幅度小）
第三代教师 + dr 0.05 @28,800	−0.0048 / −0.0081	转移放大（旧教师 −0.0031）；冠军

路径中段的容量与步数步骤增益更小（如 −0.0033 / −0.0059），时长轴在 28,800 步饱和（再翻倍到 43,200 步的配对差 +0.0016 / −0.0037）。**dropout 0.2 @14,400 步**配对 +0.0299（2/2 同向），「大 + 重正则 + 长」的角落并不存在；**weight decay 0.05 → 0.02** 配对 +0.0016，底部在 0.05；**WSD 调度**输 0.0161（机制见第 6.6 节）。

MTP 辅助损失没有进入最终模型。`student.py` 有可选的 `mtp_k`（默认 0）与 `forward_with_mtp()`（第 j 个头预测 `ids[:, t+j+2]`），**只在训练 时使用**，不花评测预算。1,200 步筛选时 w=0.1 曾过线（−0.0175），但 7,200 步的配对复核未转出增益（1.4794 vs 同配方对照 ~1.470），又一个 「短计划结论不外推」的实例。速度跑纪录里的 MTP 是**捆绑提交**（连同 解绑 / lr / weight decay 合计约 2.4%）。

6. 批判性分析

6.1 噪声地板与统计分辨力

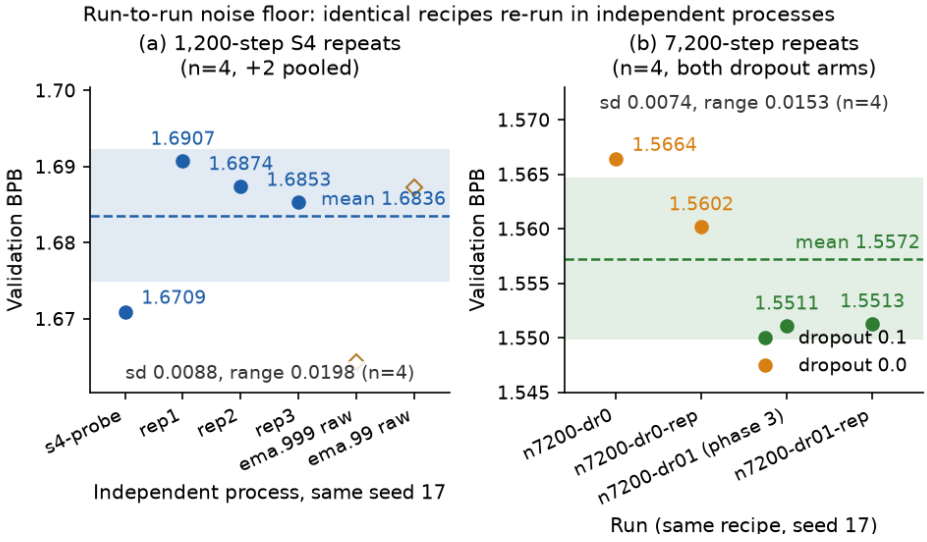
本机 CUDA 训练在进程之间不是逐位可复现的：同命令同 seed，小模型 60 步后 `max|ΔW| = 4.7e-3`，两个 control run 的 checkpoint 哈希不同——这是 进程级 kernel 非确定性。

散度来源	样本	sd	极差
同一 1,200 步配方	4 n=6	**0.0088**（n=6 时 0.0107）	0.0198（n=6 时 0.0264）
同一 7,200 步配方	4	**0.0074**	—
1,200 步另一配方的三 seed	3	0.0035	0.0068

⇒ **单次运行的分辨力 ≈ 0.02 BPB**；1,200 步上估出的「seed 噪声 ≈0.007」偏乐观。对所有 <0.02 的差值遵循两条原则：(1) **配对复现** ——dropout 两臂各 2 run、蒸馏两臂各 2 seed、EMA 4/4，落在 0.01–0.02 的差值只按「双 seed 配对同向」采信；(2) **只用 CPU fp32 最终值**—— `--eval-every` 的中间点是训练设备打分，与最终点可吻合到小数点后 4 位，但不是同一次测量。**小差值只有配对才可读**：单跑 0.0153 的差值配错 了样本，两 run 均值给的是 0.0121。

选择偏差需要说明：报告的冠军 val BPB 是约 100 个 run、每个 run 内 raw/EMA 两次选择、再加每 1,200 步快照的逐点比较 之上的**最小值**。在 7,200 步的 sd≈0.0074（14,400 步的 seed 极差 0.0089）下，这么多层选择会把「最优 run 的 val」系统性地压低于「该配方 的真实期望」约 0.5–1 个 sd（≈0.004–0.009）。因此本报告一律同时给出 **配方均值**与**单点最优**，所有外推到 test 的预测都用配方均值；冻结后 那一次 test 测量同时就是对这种选择偏差的实证校正。另注：0.02 是「单次 运行的配对预算」，不是噪声地板；预登记的晋级线 0.01 低于 2σ。见图 4。

图 4. 噪声地板：(a) 同一 1,200 步配方的重复运行（n=4，另加 2 个合并样本）与 (b) 7,200 步重复运行（n=4，含两个 dropout 臂），附 sd 带（CPU fp32 validation）



6.2 短计划结论的外推被长计划推翻

1,200 步的网格上曾外推：「学生只比教师高 0.027，所以 0.027 是蒸馏在该 步数下还能买到的**硬天花板**」，预期 7,200 步下蒸馏「持平或略好」， 不值得为它牺牲 dropout 0.1。7,200 步的配对实验推翻了它：**−0.0453**， 远大于 0.02，且超出当初估计的上界 0.027。两条错因：**双教师的几何平均 软目标优于任何单教师**（单教师上界不约束双教师）；**软目标在长计划下 持续起正则作用**，而不蒸馏那一路已走平。事后修正：蒸馏臂对着的第二位 教师是**退化的**（1.5447 > 学生最终值 1.4702），即便如此仍赢 0.045； 「换更好的教师增益更大」已被**推翻**——换用三个个体更强的 EMA 教师 （1.4905 / 1.4783 / 1.4760）后学生反而退步（1.4952/1.4849 vs 1.4752/1.4702），因为 EMA 让教师分布趋同变尖、软目标多样性下降。

6.3 大教师的长计划过拟合与 EMA 修复

三个 ⩾18.6M 的教师**全部在其最终步之前反弹**：20.1M 的 w512 d6 h8 教师在 7,200 步的终点 1.5447，最低点是第 6,000 步的 1.5267 （**+0.0180**）；同一条 20M 配方的最低点在不同 run 里分别出现在 4,800 步与 6,000 步——**停止点不可复现**。 修复是**教师端 EMA**：三个 EMA 教师的收益 −0.0341 / −0.0537 / −0.0657， 各自 raw 臂与非 EMA 双胞胎只差 0.001–0.004——**收益完全来自对权重轨迹 做平均，而非训练变好**；EMA 的收益在教师尺度上远大于学生尺度（学生 −0.0202），最终配方仍用最初的非 EMA 双教师。

6.4 预测质量与计算成本的权衡

收益列**负值 = 改善**（val BPB 下降量）。全部 CPU fp32 validation； 评测成本相对 32.7 s 预算。

杠杆	收益（val BPB）	训练成本	评测成本	证据
架构栈 + Muon + dropout + 容量	**−0.183 ~ −0.232**（打包，不可归因；Muon 单杠杆 −0.09 ~ −0.13）	6.1× 参数，步时 +8–14%	val 7.7–9.2 → 20.7–23.8 s	双 seed
容量 S2→S4 / S4→S5（1,200 步）	−0.0506 / −0.0236	+1.31M / +1.34M 参数	val 17.07→20.56 / 17.62→19.31 s	单次 + 分布对照
蒸馏一代	**−0.0453**（7,200 步配对）	步时 2.4× + 教师血统	**零**	双 seed
born-again 二代	−0.0044；与 28,800 步叠加 −0.0121（**超可加**）	零	零	2/2
EMA（匹配 horizon）	−0.0202；调度相关（第 6.6 节）	可忽略	**零**	4/4 选中
weight decay 0.1→0.05	**−0.0237**（最大单旋钮）	零	零	双 seed
长计划 7,200→14,400	−0.0215	2× 步数	零	双 seed
dropout 0.2 对 0.1	**+0.0299**（有害）	可忽略	零	2/2
教师端 EMA（作教师组）	**+0.0174**（反输非 EMA 双教师）	1,273–3,522 s	零	2/2

收益最大的两个杠杆（架构栈、蒸馏）一个买在推理时间上（冠军架构用掉 约 88% 的预算，第 8 节），另一个不花评测预算；正则类旋钮（weight decay、dropout）在长计划区间呈明确的「倒 U」——两轴的底都在 0.05 / 0.1，向任一方向加码都亏钱；「扩大模型本身换收益」的尝试（w320、解绑、 更大的非 EMA 教师）要么被时间预算挡住，要么被过拟合吃掉。

6.5 为什么在本协议下 validation BPB 是可信的选型指标

「指标在涨但模型其实在变好」的顾虑（训练目标与下游指标脱钩）在这里 **不存在**：要的是**测试集 BPB**，手上的指标是**验证集 BPB**——同一个 东西、同一套协议，只换了批文章；指标就是目标本身，背后没有「另一个更 真的能力指标」，因此没有 Goodhart 空间，val BPB 反弹，冻结后的 test 几乎必然跟着变差。残余风险只有 val→test 的**抽样漂移**，靠「冻结前不碰 test + 多 seed 复核」兜底；选型规则（0.02 晋级门槛、内部 24 s 门槛）只用 validation 与实测计时决定。

6.6 EMA 的收益取决于调度

在 14,400 步上做过一次干净的调度单变量 A/B（同 config / seed / 教师 / 优化器 / EMA，只差 `--schedule`）：cosine 的 EMA 比自己的 raw 好 0.0171，而 WSD 的 EMA 反而比自己的 raw **差** 0.0424——WSD 把收益压在 最后 20% 的 cooldown 里，而 ema-decay 0.9995 的等效窗口（约 2,000 步） 横跨这段剧变，平均值落在「尚未冷却」的权重上。按实际采用的选型规则 （raw/EMA 取优）WSD 输 0.0161，只看 raw 权重时它反而好 0.0009（噪声 级）。由此得到两点：(a) **EMA 不是免费午餐**，它隐含「权重在末端已接近 平稳」的前提；(b) 评价调度改动必须连 EMA 一起视为一对旋钮。WSD 未被 采纳，但它的 raw 轨迹说明**稳定段高学习率并没有把训练推得更远**——收益只来自冷却段。

7. 成本披露

按 `code/RUN_LOG_TEMPLATE.csv` 的列披露。 `processed_targets_including_ancestry` 把**血统**算进去：蒸馏的学生把 教师的训练目标数也计入。下表统一为 `threads` 4、`train_precision` fp32、`selected_on` = validation、评分用 CPU。

run_id	方法	steps	血统目标数	参数	train s	val BPB	test BPB
`e0-baseline`	基线	1,200	9,830,400	1,088,256	23.07	2.0711	**2.1013**
`e3-s17/s42` / `e2-s17/s42`	6.6M 学生 / + 双教师蒸馏	7,200	58,982,400 / **157,286,400**	6,640,128	1662.2/1103.7; 2652.6/2645.4	1.5169/1.5191; 1.4752/**1.4702**	未跑
`e1l-s17` / `e3l-s17/s42` / `e2l-s17/s42`	基线 / 无蒸馏 / 三教师蒸馏（`e1l` 单 seed）	14,400	117,964,800 ×2 / **265,420,800**	1,088,256 / 6,640,128 ×2	618.1 / 3201.0 / 3416.1 / 6490.0 / 6500.9	1.6796 / 1.4977 / 1.4953 / 1.4777 / 1.4775	未跑
教师组（8 run）	预训练，不提交	4,800–7,200	39.3M–59.0M	15.0M–20.1M	926.9–3,521.9	1.4760–1.5447	未跑
	冻结配方：28,800 步 +	28,800	**1,040,222,400**	8,907,696	1695.7	**1.407431**	**1.426939**

run_id	方法	steps	血统目标数	参数	train s	val BPB	test BPB
`s6-gen3dr005-s42`	第三代 born-again 双教师蒸馏						

汇总（派生量）：已落盘训练 run 的 `train_seconds` 直接相加为 **202,443 s ≈ 56.2 GPU·小时**（含并行膨胀，**未计**每次约 7 s 的 BPE 重编码 `preparation_seconds`）。评测计时：validation 评分从 5.75 s（基线，本地）到 26 s 量级（学生，本地 3070L）；服务器 CPU 较慢，同 模型约 29–40 s——只在同一台机器上比。

实现与搜索成本：实现文件只有 `student.py` 与 `train.py` 两个；搜索 共 **110 个已落盘 run**（按 `metrics.json` 计数，含冒烟与 10 步兼容性 检查）。逐 run 明细见 `submission/RUN_LOG.csv`（含 test 实测）与 `report/evidence.csv`。

8. 局限与风险

1. **早期证据以单 seed 为主**，1,200 步快筛时代的容量、步数结论是单次/ 单尺寸；但从组装起每一步都是同 seed 配对 + 双 seed 复核。
2. **val→test 的外推只有一个实测点**。E0 的 val→test 对（比值 1.01459 / 加性 +0.0302）是全项目唯一的换算依据；两个 split 是不同文章，抽样 漂移无法排除。
3. **教师停止点不可复现。** 三个大教师全部反弹，同一条配方的最低点在 不同 run 里不同；`train.py` 只保存最终 checkpoint，反弹无法事后回避。
4. **规模贴近 5× 时间预算的边界。** 8.9M 参数的本机实测用掉约 88% 的 validation 预算（25.5 s / 28.9 s 折算 test 对 32.75 s），服务器上约 78%；再扩大容量必须先过计时这一关。

9. 参考文献

1. G. Hinton 等. Distilling the Knowledge in a Neural Network. arXiv:1503.02531。
2. K. Jordan. Muon（kellerjordan.github.io/posts/muon/）；arXiv:2502.16982。
3. K. Jordan 等. modded-nanogpt（github.com/KellerJordan/modded-nanogpt）。
4. BabyLlama: knowledge distillation from an ensemble of teachers for BabyLM。
5. J. H. Cho, B. Hariharan. On the Efficacy of Knowledge Distillation. ICCV 2019。
6. T. Furlanello 等. Born-Again Neural Networks. arXiv:1805.04770。
7. M. Muennighoff 等. Scaling Data-Constrained Language Models. arXiv:2305.16264。
8. M. Merity 等. Pointer Sentinel Mixture Models. arXiv:1609.07843。